

河南科技大学

HENAN UNIVERSITY OF SCIENCE & TECHNOLOGY

毕 业 设 计（论 文）

题目 基于深度学习的多目标检测与分割系统的设计与实现

姓 名	<u>黄皓杨</u>
学 院	<u>软件学院</u>
专 业	<u>软件工程</u>
指导教师	<u>李昌清 孙辉</u>

2025 年 5 月 25 日

学位论文写作声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

论文作者签名：黄皓杨 日期：2025 年 5 月 25 日

学位论文使用授权说明

本人完全了解河南科技大学关于收集、保存、使用学位论文的规定，即：按照学校要求提交学位论文的印刷本和电子版本；学校有权保存学位论文的印刷本和电子版，并提供目录检索与阅览服务；学校可以采用影印、缩印、数字化或其它复制手段保存论文；在不以赢利为目的的前提下，学校可以将学位论文编入有关数据库，提供网上服务。（保密论文在解密后遵守此规定）

论文作者签名：黄皓杨 导师签名：李昌清

日期：2025 年 5 月 25 日

基于深度学习的多目标检测与分割系统的设计与实现

摘 要

全球城市化快速发展，城市道路、校园周边、商业街区交通流量显著增加，交通场景日趋复杂。智能交通系统需在多目标的场景中精准识别定位行人、机动车、交通标识等目标，为车辆决策控制提供环境数据，实现智能交通管理与自动驾驶。

传统目标检测算法应用于多目标场景存在明显的不足，目标漏检率高、实时处理能力弱、计算资源消耗大，限制智能交通系统的实际应用。针对上述情况，本文使用 PyTorch 深度学习框架结合 YOLOv8 算法，设计并实现了一个高效的多目标检测与分割系统。YOLOv8 算法凭借高效检测性能与轻量化架构，在保证检测精度的同时大幅提升推理速度，能快速的识别多目标场景中的行人、车辆、交通标志等目标，在实例分割的过程中不仅可快速辨别不同类别目标，还可为每个目标生成精确像素级掩码，实现目标识别与精细分割一体化。

系统通过 PySide6 技术搭建交互式图形操作界面，支持图像、视频和实时摄像数据输入，用户在界面上可直观便捷操作，可以实时显示检测与分割的结果，便于用户对模型的输出进行分析。

关键词：深度学习；目标检测；实例分割；YOLOv8

THE DESIGN AND IMPLEMENTATION OF MULTI-OBJECT DETECTION AND SEGMENTATION SYSTEM BASED ON DEEP LEARNING

ABSTRACT

The rapid development of global urbanization has led to a significant increase in traffic flow on urban roads, around campuses, and in commercial districts, making traffic scenarios increasingly complex. Intelligent transportation systems need to accurately identify and locate pedestrians, motor vehicles, traffic signs, and other targets in dense scenarios to provide environmental data for vehicle decision-making and control, thereby achieving intelligent traffic management and autonomous driving.

Traditional target detection algorithms show obvious limitations in multi-target scenarios, such as high miss rates, poor real-time processing, and heavy computing resource consumption, restricting the practical application of intelligent transportation systems. To address this, this paper designs and implements an efficient multi-target detection and segmentation system using the PyTorch framework with the YOLOv8 algorithm. YOLOv8's efficient detection performance and lightweight architecture ensure both accuracy and faster inference speed, enabling quick identification of pedestrians, vehicles, traffic signs, and other targets in dense scenes. During instance segmentation, it not only distinguishes target types rapidly but also generates precise pixel-level masks for integrated recognition and fine-grained segmentation.

The system builds an interactive graphical operation interface through PySide6 technology, supporting the input of images, videos, and real-time camera data. Users can operate intuitively and conveniently on the interface, and the detection and segmentation results can be displayed in real time, facilitating users' analysis of the model's output.

KEY WORDS: deep learning; target detection; instance segmentation; yolov8

目 录

第 1 章 绪 论	1
§ 1.1 研究背景及意义	1
§ 1.2 国内外研究现状	2
§ 1.3 研究方法与内容	3
第 2 章 相关理论介绍	4
§ 2.1 神经网络	4
§ 2.2 卷积神经网络	5
§ 2.2.1 卷积层	5
§ 2.2.2 池化层	6
§ 2.2.3 激活函数	7
§ 2.3 本章小结	8
第 3 章 实验数据集与评价指标	9
§ 3.1 实验数据集介绍	9
§ 3.2 实验数据增强与划分	9
§ 3.3 模型评价指标	10
§ 3.4 本章小结	12
第 4 章 实验技术原理与界面设计	13
§ 4.1 YOLOv8 目标检测技术	13
§ 4.2 YOLOv8 实例分割技术	14
§ 4.2.1 YOLACT 实例分割算法	14
§ 4.2.2 YOLOv8 实例分割架构	15
§ 4.3 界面设计	16
§ 4.3.1 系统流程图	16
§ 4.3.2 界面设计过程	17
§ 4.3.3 系统界面展示	18
§ 4.4 本章小结	20

第 5 章 实验环境与结果分析	22
§ 5.1 实验环境	22
§ 5.2 实验结果分析	22
§ 5.3 本章小结	26
第 6 章 总结与展望	27
§ 6.1 总结	27
§ 6.2 展望	27
参考文献	28
致 谢	30

第 1 章 绪 论

§ 1.1 研究背景及意义

在计算机视觉领域中，目标检测和图像分割一直都被当作特别关键的核心研究方向，它们有着关键的学术价值以及很大的技术挑战性。随着人工智能技术的快速发展，跨行业应用场景中对图像进行理解和分析的需求也在不断地增长，这种情况下，该技术体系的关键作用日益凸显。

目标检测是在图像中定位目标并标记位置，通常用边界框标记；实例分割不仅要确定边界框，还要准确地绘制出每个目标的形状。实例分割技术在很多领域都有广泛的应用。在智能交通方面，车辆行驶时要实时了解周围环境，通过实例分割识别道路、行人、车辆、交通信号灯等，确定这些目标的位置和形状，为车辆规划路线、控制速度和安全决策提供重要依据，是实现车辆安全高效行驶的关键技术。

以掩码区域卷积神经网络（Mask Region - based Convolutional Neural Network, Mask R - CNN）为代表的实例分割方法存在模型结构复杂、实时性差和语义信息丢失的问题。这种方法难以满足现实场景中的应用需求^[1-2]。

YOLOv8 作为 YOLO 系列的算法，在目标检测与分割任务中表现出了高精度与实时性优势。YOLOv8 网络采用了经典的三部分架构：Backbone 骨干网络和 Neck 颈部网络完成图像特征提取和融合，根据任务需求设计的 Head 检测头输出结果。在实例分割任务中，YOLOv8 检测头与分割头协同工作，检测头负责定位目标的预测框和类别，分割头负责生成一组原型掩码和掩码系数，通过掩码系数和原型掩码线性组合的方式生成每个目标的掩码，然后通过双线性插值进行上采样，将掩码调整到原始图像大小，最后掩码与目标的预测框一起输出，作为最终的实例分割结果。

多目标检测与分割技术对智能交通意义重大，能大幅度提升检测精度和响应速度，为智能交通系统提供精准环境数据，车辆可以在复杂路况中准确识别行人、车辆、交通标识并合理决策，还能实时监测交通流量，为管理部门提供可靠数据，优化城市交通运行效率。

§ 1.2 国内外研究现状

在目标检测领域,国内研究人员许谨辉及其团队提出一种新的多目标检测模型,在 YOLOv8n 的基础上引入卷积注意力模块(CBAM),通过空间和通道双重注意力机制,提高了对关键特征的提取能力,还在网络中增加小目标检测层,由原来的 3 层增加到 4 层,从而更好地提取细小特征,提升了对小尺寸目标的检测性能。平均精度均值(mAP)提高了 3.4%,达到了 97.5%,且检测速度达 46.35 帧/s,满足实时性检测的需求^[3]。陈晓东提出了基于 YOLO 车道多目标检测识别系统,该系统可以实时地检测出车道目标及类型的概率,同时通过多次实验,设置合适置信度,提高识别准确性,对于车辆和行人识别准确率在 85%以上^[4]。此外,国外研究人员 Muhammad Wahab Hanif 及其团队在 YOLOv5 中引入了一种解耦头来增强特征融合,提高网络模型的定位精度,从而能够快速捕获多尺度目标特征,以解决多目标检测精度低和难以识别小目标的挑战^[5]。Li Yiming 及其团队在 YOLOv5 的网络结构上增加了微目标检测层和双头机构,以提高对微小目标的检测能力,利用变焦损失在非极大值抑制过程中实现更准确的排序,以解决目标遮挡问题。所提模型的准确性、召回率和平均精度均值(mAP)都得到了极大的提高^[6]。

在图像分割领域,国内张纵驰及其团队使用多尺度注意力 MSA 模块替换 YOLOv8-seg 网络骨干的 C2f 模块,改进特征表示的同时实现网络轻量化;在网络的小目标检测层加入注意力机制层,增强小目标缺陷的检测能力;结果相较于原算法在目标框(BOX)和掩码(MASK)的平均精度均值(mAP)分别提高 4.6%和 5.3%,且检测速度提升了 9.1%^[7]。李利及其团队针对具有复杂堆叠场景下的实例分割问题,提出了一种融合 YOLOv8 与双层特征网络策略的实例分割算法,通过双层图卷积网络(graph convolutions network, GCN)实现双分支特征融合,减弱堆叠情况对被遮挡物体特征的影响,从而解决复杂堆叠遮挡下的实例分割问题。相较于原 YOLOv8 算法,检测 mAP50 提高了 7.9%,分割 mAP50 提高了 5.4%^[8]。在另一项研究中赵南南及其团队提出一种基于改进型 YOLOv8 的实例分割算法(DE-YOLO)使用可变形卷积结合 C2f 卷积层,突破原始卷积限制,提升可变性,采用动态聚焦机制的边界框回归损失(WIoU)替代联合完全交并(CIoU)损失函数进行质量评估,优化检测框定位,提升分割精度。与传统网络相比,平均精度均值(mAP)提高了 3.2%^[9]。国外研究人员 Dimas Firmanda Al Riza 及其团队在 YOLOv8 框架内开发了 YOLO-CoLa 模型,在网络主干网中集成了创新的大型选择性内核块,取代

了 C2f 模块以提高检测精度，应用数据增强来减轻与训练图像可用性相关的限制。实验结果表明有较高的应用价值^[10]。

§ 1.3 研究方法与内容

本文旨在通过使用 YOLOv8 算法，探讨如何高效的对多目标进行检测与分割，以解决传统方法存在的实时性差、效率低等问题。本文研究的内容主要包括以下几点：

1. 利用深度学习算法解决多目标检测与分割中目标遮挡、小目标难以识别的问题，提升检测的精度与全面性。
2. 利用 YOLOv8 算法高效处理多目标检测与分割满足实际的应用需求。
3. 利用 PySide6 制作交互界面，支持图像、视频和实时摄像数据的输入，可实时向用户展示结果，便于实际应用推广。

第 2 章 相关理论介绍

§ 2.1 神经网络

神经网络模仿的是人脑神经元网络结构，是图像识别中重要的人工智能技术，是依据人脑神经元的连接结构以及信息传递机制来进行构建的，它的核心架构是由数量很多且相互连接在一起的神经元单元所组成的。神经元通过连接传递信息，每个连接处有权重可以调节信息传递强度。神经元接收到的输入信号，会先经过加权运算的过程，然后再由激活函数进行处理，在这一系列操作之后，输入信号就被转化成了输出值，而这个输出值会作为后续神经元的输入信号，开始进行传递。

神经网络是由输入层，输出层和隐藏层组成，如图 2-1 所示。输入层的作用是负责接收初始的数据，隐藏层要执行多层次的特征转换，输出层的任务则是生成最终的预测结果，各个神经元之间的连接关系是凭借可以学习的权重参数来进行建模的，这些权重参数的作用是量化神经元之间信息传递的强度。在模型训练的过程当中，先是通过前向传播算法来计算网络的输出，接着基于误差反向传播机制对权重矩阵进行迭代更新，能够实现网络性能的持续优化。




图 2-1 神经网络架构

训练时神经网络正向传播从输入层接收原始数据，数据传入隐藏层后神经元接收输入层所有信号，各信号乘对应权重（反映连接强度）后累加并加

上一个偏置项,经激活函数处理输出作为下一层输入,直到数据传到输出层。反向传播先随机初始化权重再正向传播得到输出,使用损失函数对比实际与期望输出算出误差,之后计算权重误差梯度,使用梯度下降算法调权,减小误差值并向前层传递误差,反复进行正反向传播和误差计算,直到训练次数够或模型收敛,靠链式法则和梯度下降优化权重提升预测准确性。

§ 2.2 卷积神经网络

卷积神经网络是一种典型的深度学习算法,凭借非常出色的特征提取能力以及稳定的性能表现,在计算机视觉、医疗与生物信息以及遥感与地理信息等人工智能研究的领域里得到了广泛的应用,与传统的依靠人工来设计特征提取方法的技术路线相比,这种网络架构通过逐层的进行卷积运算,实现了从低层次特征到高层次特征的自动提取与优化。在结构组成中,卷积神经网络主要包含了卷积层、激活函数和池化层等核心的组件,并且有局部连接和权值共享的特性。下面将按照顺序对卷积层、池化层以及激活函数这三个关键的组成部分进行简要的介绍。

§ 2.2.1 卷积层

卷积神经网络的核心架构基本上是由卷积层来构成的,在这个卷积层当中包含了若干个卷积核,而这些卷积核会借助执行卷积运算的方式,从输入的数据里面提取出关键的特征。卷积运算的过程是先接收输入特征图,把它当作处理的对象,然后借助卷积核进行数学运算,最后会生成带有更高层次语义信息的输出特征图。




图 2-2 卷积过程

如图 2-2 所示,卷积核借助滑动窗口的机制,会在输入特征图对应的区域开展运算,这些卷积核的参数并不是提前就设定好的超参数,而是卷积神经网络的训练

过程动态地学习得到的，在经过充分的训练之后，不同的卷积核能够有效的提取出不同类型的特征。

卷积层的卷积效果由卷积核、步长、填充三个核心参数所决定。卷积核是卷积运算的权重矩阵负责特征的提取。步长是卷积核在输入特征图滑动间隔，步长越大输出特征图的尺寸越小，实际应用需平衡特征的细节与计算量。填充通过在输入特征图边缘补充像素，可以有效的避免边缘信息丢失，保证数据边界特征提取。假设输入特征图的尺寸为 $W_{input} \times H_{input}$ ，卷积核的尺寸为 $F \times F$ ，步长为 S ，填充数为 P ，输出特征图尺寸为 $W_{output} \times H_{output}$ ，计算公式如(2.1)和(2.2)所示：

$$W_{output} = \frac{W_{input} - F + 2P}{S} + 1 \quad (2.1)$$

$$H_{output} = \frac{H_{input} - F + 2P}{S} + 1 \quad (2.2)$$

§ 2.2.2 池化层

池化层一般会作为卷积层之后的处理模块，它的核心功能主要是实现对特征图维度进行有效的压缩，能够有效的减少网络计算时的复杂度，还可以提高模型在训练过程当中的稳定性。池化层保留了特征图重要部分、舍弃一些细节，可以帮助模型在不同数据上都能有好的表现。目前最广泛使用的池化操作主要是包含了两种典型性的方法，一种是基于局部区域最大值提取方式的最大池化(Max Pooling)，另一种则是借助计算邻域均值来实现特征降维目的的平均池化(Average Pooling)。




图 2-3 最大池化和平均池化过程

如图 2-3 所示，最大池化通过计算特征图中数值最大的元素当输出，直接挑选特征图数据里最突出的特征，例如图像边缘、角点这些重要地方就会更加明显。平

均池化通过计算特征图里面所有元素的平均值，然后把这个平均值当作输出的特征值，能保留住数据整体的特征分布，防止一些极端数值影响最终结果。

§ 2.2.3 激活函数

激活函数是卷积神经网络里面关键的一个组成部分，一般在卷积运算之后，对特征图进行非线性的变换和处理，把这种非线性变换的机制加到神经网络中，能让神经网络具有学习复杂函数映射关系能力。下面将对 Sigmoid 和 SiLU 激活函数进行简要的介绍。

Sigmoid 激活函数图像，如图 2-4 所示，函数值范围在 (0,1) 之间，可以将任意实数映射到这个区间。数学表达式如下：

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2.3)$$




图 2-4 Sigmoid 激活函数

Sigmoid 激活函数由于它的输出值域是在(0,1)这个范围的特性，被广泛地用在概率建模这个领域中，它有连续可微的数学特性，为反向传播算法里的梯度计算创造了便利的条件，但是函数在深层神经网络的训练过程中，会有突出的局限性，当输入值偏离零点区域的时候，它的导数会呈现出指数级的衰减趋势。这种梯度消失的现象会严重地妨碍误差信号在反向传播过程中的有效传递，最后会造成网络参数更新的效率变得很低，甚至会使得训练过程没办法达到预期的收敛状态。

SiLU 激活函数图像，如图 2-5 所示，函数在整个定义域上是平滑的，没有尖锐的拐点，这种平滑性可以帮助梯度下降算法更稳定地收敛。数学表达式如下：

$$\text{Silu}(x) = x * \frac{1}{1 + e^{-x}} \quad (2.4)$$




图 2-5 SiLU 激活函数

SiLU 激活函数的表达式中包含了 Sigmoid 函数，在实际的计算过程中，深度学习框架通常会对 SiLU 函数进行优化，使其计算效率更快，能够在不增加过多计算成本的情况下提高模型的整体性能。

§ 2.3 本章小结

本章主要系统讲解了深度学习基础理论，简要阐述了相关知识。首先介绍了神经网络的架构以及前向传播和反向传播的过程，然后从卷积层、池化层和激活函数三个方面介绍卷积神经网络，并对卷积方式提取图像的特征、最大池化和平均池化两种方式减低特征图的数据维度以及 Sigmoid 激活函数和 SiLU 激活函数实现非线性变换进行了简要的说明。

第3章 实验数据集与评价指标

§ 3.1 实验数据集介绍

在对多目标检测与分割的研究中，数据集的选择会直接影响模型的性能和结果的精度。本文选取了来自汽车行车记录仪 4K 超清视频，对视频进行按帧分割处理，最终选出 1500 张多目标场景的图片，通过 Labelme 工具进行手动标注后作为实验数据集。数据集包含汽车（car）、行人（person）、建筑物（building）、树木（tree）、道路（road）、交通标志（traffic sign）和交通信号灯（traffic light）7 个类别，包括了城市场景常见的目标。数据展示如图 3-1 所示：




图 3-1 数据集图片展示

§ 3.2 实验数据增强与划分

1. 实验数据增强

多目标检测与分割中数据集规模和样本的多样性会影响模型的训练效果，人工标注大量数据耗时费力，计算机视觉领域常用数据增强技术解决数据不足问题。

数据增强通过镜像翻转、旋转、缩放、平移、裁剪、颜色变换等操作处理原始数据生成新的样本，在保留图像关键信息的同时增加了数据多样性，让模型对数据变化更具有适应性和鲁棒性。数据集处理如图 3-2 所示。



图 3-2 实验数据集增强操作

图 3-2 中(a)为数据原图,(b)为经过旋转之后的图像,(c)为经过缩放后的图像。在本实验中使用了数据增强技术扩充了现有数据集的数量,以有限的原始数据量生成新样本,缓解了实验中数据量不够的难题,降低了大量标注数据的难度以及减少了在标注过程中出现的人为失误,能够有效地提升模型进行特征提取的能力,而且还可以显著地降低在训练过程当中模型对于特定样本所产生的过度依赖的问题。

2. 实验数据划分

实验数据集总共有 1500 张图片,经过数据增强后扩充到了 3000 张。按照 9:1 的比例划分为训练集和验证集。训练集是用来在训练过程中对参数进行优化,通过不断地迭代调整,能够让模型有效地捕捉到数据所有的内在特征以及分布规律,实现损失函数的最小化。在每一轮训练结束之后,模型会在验证集上开展性能测试,在验证集中并不会对参数进行更新,能够有效地监测模型是否存在过拟合现象或训练效果不佳等问题。

表 3-1 实验数据集的划分

数据集	数量
训练集	2700
验证集	300

§ 3.3 模型评价指标

评估模型在任务中的性能需用到评价指标,常用的模型评价指标包括准确率(Accuracy)、精确率(Precision)、召回率(Recall)、F1 分数(F1-Score)和平均准确率均值(mean average precision, mAP)等从多方面评估模型的性能。这些指标为模型在分类检测等任务表现提供量化的评估标准,并且构成了完整的模型评估体系。下面将对这些指标进行简要介绍。

为了更方便地进行评价指标的介绍以及将这些指标进行比较,首先需要与

评价指标相关的基础计算量给出明确的定义。

表 3-2 模型预测情况分类

真实情况 \	预测情况	
	正例	反例
正例	TP	FN
反例	FP	TN

TP 表示模型正确预测的正样本，FP 表示模型错误预测的正样本，TN 表示模型正确预测的负样本，FN 表示模型错误预测的负样本。

1. 准确率 (Accuracy)

准确率是用来评估模型性能的一个核心指标，是指模型正确预测出来的样本数量，去除以总体样本的数量。具体的公式如下：

$$\text{准确率(Accuracy)} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.1)$$

2. 精确率 (Precision)

精确率(查准率)是指模型预测正确的正样本个数 (TP) 占模型预测为正样本的个数 (TP+FP) 的比例。具体的公式如下：

$$\text{精确率(Precision)} = \frac{TP}{TP + FP} \quad (3.2)$$

3. 召回率 (Recall)

召回率(查全率)是指模型预测正确的正样本个数 (TP) 占真正的正样本个数 (TP+FN) 的比例。具体公式如下：

$$\text{召回率(Recall)} = \frac{TP}{TP + FN} \quad (3.3)$$

4.F1-Score (F1 分数)

F1-Score 指的是精确率和召回率的调和平均值，数值综合考虑了精确率和召回率。具体公式如下：

$$F1 = \frac{2TP}{2TP + FP + FN} \quad (3.4)$$

5.P-R 曲线 (Precision-Recall Curve)

根据得到的不同召回率 (Recall) 和精确率 (Precision) 可以绘制出 PR 曲线，

PR 曲线越靠近右上角，表明模型性能越好，代表着模型在保持高召回率的同时还能维持高精确率。PR 曲线下的面积是一个关键的量化指标，这个指标的数值越大，就越能全面体现出模型在不同分类阈值条件下的稳定性和综合性能优势。

6. 平均准确率均值 (mean average precision, mAP)

平均准确率均值 (mean average precision, mAP) 是对多个类别 AP(Average Precision)的平均值，AP 是对单个目标类别进行计算，评估的是不同召回率下的精确率平均值，可以用于评估模型在该类别上的准确性。而 mAP 综合考虑了所有的目标类别，能够更加全面地评估模型的整体性能。

§ 3.4 本章小结

本章主要介绍了实验中的数据集和实验评价指标。首先对数据集的来源及标注信息进行了说明，然后通过使用数据增强技术，扩充现有数据集的规模，把扩充之后的数据集，按照提前设定好的比例分成了训练集和验证集。训练集主要的作用是对模型的参数进行优化，开展特征学习，而验证集主要的作用是评估模型的泛化能力，并且为超参数的调优提供客观的依据。最后对常见的模型评价指标：准确率、精确率、召回率、F1-Score、P-R 曲线以及平均准确率均值进行了简要的介绍。

第 4 章 实验技术原理与界面设计

§ 4.1 YOLOv8 目标检测技术

YOLOv8 延续了 YOLO 系列基于骨干网络和检测头的经典设计思路，在骨干网络部分，采用改进的 CSPDarknet 为基础网络，通过 CSP 结构大量减少计算量和参数量，同时也保证了特征的丰富性，提升了对多目标图像的特征提取效率。通过使用多尺度的池化操作，对输入的特征图进行信息融合，能够有效的增强网络对不同目标的特征表达能力。在多目标的检测场景中，无论是小尺寸的目标，还是密集排列的目标，骨干网络都能够快速的精准提取这些目标的关键特征。网络结构如图 4-1 所示。




图 4-1 YOLOv8 网络结构

在检测头部分，采用了解耦头设计思想，将分类任务与边界框回归任务分支分离。这种设计可以在网络训练时，各任务分支专注学习相应的特征，避免信息

的相互干扰，显著提升了训练效率与检测精度。在多目标检测场景中能够更加准确地对多个不同类别的目标进行分类，并精确地确定每个目标的位置信息。

为了进一步提高在检测过程中的性能，网络结构中还使用了 Batch Normalization（批归一化）用来稳定输入数据的分布，加速模型的收敛；引入残差连接结构，使网络能够保留底层的特征信息，避免了信息的丢失；同时还采用了 SiLU 激活函数代替传统的 ReLU 激活函数，可以让模型更加准确地学习到目标特征的差异，从而提高检测过程中的准确率。

§ 4.2 YOLOv8 实例分割技术

§ 4.2.1 YOLACT 实例分割算法

YOLACT（You Only Look At Coefficients）是一个实例分割算法，它的主要思想是通过预测一组与类别没有关系的原型掩码（prototypes）和每个目标实例的掩码系数来生成每个目标的精准的分割掩码，这种方法不仅提高了实例分割过程中的准确性，还保证了实时性。网络架构如图 4-2 所示。




图 4-2 YOLOACT 网络架构

在图像的特征提取过程中，使用多个卷积模块逐步提取图像不同层次的特征信息，为后面的过程提供了基础的特征图。这些不同尺度的特征图通过特征金字塔（Feature Pyramid）组合在一起，有利于网络能够更好地获取到不同大小目标的特征信息，增强了网络对不同大小目标的检测能力。预测头（Prediction）负责预测出每个目标的类别、边界框信息以及掩码系数。掩码系数是一组与类别没有关系的系数，用于从原型掩码中生成每个实例的精确的分割掩码。ProtoNet（原型网络）通

过全卷积的过程生成一组原型掩码（**prototype masks**），这些原型掩码可以认为是不同物体实例的通用形状模板，它们包含了很多的形状信息，并不是针对特定的目标，而是具有一定的通用性，后处理过程通过线性组合的方式生成特定目标的分割掩码。预测头输出的检测结果（包括类别、边界框和掩码系数）会通过非极大值抑制（**NMS**）处理，可以去除多余的检测框，保留最好的检测结果。最终生成的实例分割掩码通过将预测的掩码系数与原型掩码进行线性组合得到的。这种线性组合方式可以使 YOLACT 灵活的适应不同形状和不同大小的目标，同时也保持了高效性。生成的分割掩码经过裁剪（**Crop**）和阈值处理（**Threshold**），去除了噪声和冗余掩码，最终得到实例分割结果。

§ 4.2.2 YOLOv8 实例分割架构

YOLOv8 在进行实例分割时，使用了 YOLACT 的核心思想，也是通过将原型掩码与掩码系数通过线性组合的方式生成目标的掩码。YOLOv8 在实例分割的过程中采用了检测头与分割头相结合的方式。网络架构如图所示 4-3 所示。




图 4-3 YOLOv8 实例分割架构

在输入的图像经过特征提取和特征融合之后，会得到三种不同尺度特征图。检测头使用这些特征图进行目标检测的相关操作，最终输出目标的边界信息、类别置信度和目标的数量。分割头会使用这些特征图生成掩码系数（**Mask Coefficients**）和原型掩码（**prototype masks**）。检测头的输出和分割头输出的掩码系数使用拼接（**Concat**）将信息进行融合，经过置信度阈值、非极大值抑制，最终会输出符合标准的目标信息。目标掩码的生成是在后处理的过程中，分割头根据融合后的信息，经过非极大值抑制，选择与目标类别匹配度最高的原型掩码（**prototype masks**），通过线性组合目标的掩码系数和原型掩码生成目标实例掩码，然后对得到的掩码

通过双线性插值的方法进行上采样，让生成的掩码与输入图像的尺寸保持一致。最后，将上采样后的掩码与目标的边界框一起输出，作为最终的实例分割结果。

§ 4.3 界面设计

§ 4.3.1 系统流程图

系统的主要流程包括选择操作方式、选择检测数据以及检测结果的展示。系统成功运行后，需要用户进行检测数据的选择，用户可以根据实际应用需求，选择不同类型的数据，包括图像数据、视频数据以及实时摄像数据，用户选择数据后，系统会将检测的结果显示在用户图形化界面中，方便用户查看。系统流程图如图 4-4 所示。




图 4-4 系统流程图

§ 4.3.2 界面设计过程

PySide6 是一款强大灵活的 GUI(图形用户界面)开发工具,具有跨平台兼容性和丰富的组件库。系统使用了 PySide6 技术搭建了直观、友好的图形化界面,并且考虑到现实场景中的用户多样化的需求在本系统中提供了多种的检测模式,用户可以根据具体的应用场景选择对应的检测方式。下面将介绍通过 Pyside6 技术在多目标检测与分割系统中的应用,包括系统界面的整体框架,各功能的实现以及用户的交互,通过科学合理的设计图像化展示界面,让系统的操作更加便捷,提高用户的操作效率。

界面的整体框架是由 Pyside6 中的 QTabWidget 来创建选项卡窗口,通过 QWidget 创建图片检测和视频检测两个功能窗口。在两个功能窗口中先创建垂直布局,然后在垂直布局中添加标签组件用于展示文本信息和图像信息;添加按钮组件用于展示功能按钮,最后把两个功能窗口添加到选项卡窗口中。

图片检测功能的实现是首先通过导入 YOLO 加载已经训练完成的模型,为后续的检测做准备。通过 QFileDialog 获取用户选择的图片路径,之后读取图片并计算图片的缩放比例,将缩放后的图片保存并显示在界面中的标签组件中,同时记录图片的路径,当用户点击开始检测后,向模型中传入检测图片的路径,检测完成后,在原图上绘制检测与分割的结果,最后统计各类别目标的数量,将检测的结果展示到界面中。实时摄像检测功能的实现是通过使用 OpenCV 库中的 VideoCapture 初始化摄像头,然后不断读取摄像头中的每一帧图像,调用 YOLO 模型对每一帧的图像进行检测,并绘制检测与分割的结果,最后将统计完成的检测结果展示到界面中。视频检测功能与实时摄像检测类似,差异是 VideoCapture 读取的内容不同,在实时摄像检测中读取的是摄像头索引号,而在视频检测中读取的是视频文件路径。

系统与用户的交互是设计了一个专门的区域用来展示系统反馈的结果,包括目标的名称和数量。通过从检测结果中获取模型支持的类别名称列表和检测到的类别 ID,去遍历统计每个类别的数量。在遍历的过程中设置了只保留数量大于 0 的类别,然后拼接成文本的形式,通过设置标签组件的值,将检测的结果设置到标签中,最后显示到系统的界面上。通过可视化的方式,让用户可以便捷、直观的了解到系统检测的结果,为后续的分析提供重要的参考。

§ 4.3.3 系统界面展示

在图片检测的功能窗口中，窗口的中间区域用来展示用户上传的待检测图片和检测后的图片，功能按钮设置了“上传图片”和“开始检测”，用户可以通过点击按钮来实现相应的操作。如图 4-5 所示。




图 4-5 系统图片检测窗口展示

在用户点击“上传图片”的按钮后，随即便会弹出图像文件的选择框，用户从中选取想要检测的图片后，图片会上传到该系统中，之后展示到中间区域。如图 4-6 所示。



图 4-6 图片检测展示

在用户点击“开始检测”的功能按钮后，系统将启动检测的过程，通过调用相应的代码，使用已经训练完成的 YOLOv8 实例分割模型对图片进行检测，会在原图像上绘制出目标的检测框、标签和掩码，统计计算出各类的目标数量，然后会把检测的结果反馈到页面中。如图 4-7 所示。




图 4-7 图片检测结果展示

在视频检测的窗口中，窗口的中间区域用来展示用户上传的检测后视频图像，功能按钮设置了“实时摄像检测”、“上传视频”功能和“停止检测”按钮，用户可以通过点击按钮来实现相应的操作。如图 4-8 所示。



图 4-8 系统视频检测窗口展示

在用户点击“实时摄像检测”的按钮时，系统将通过调用相关代码，初始化电脑所连接摄像头，以外部真实环境为输入，循环读取视频流的帧数，实时的对每一帧图像进行检测并将结果图像展示到窗口的中间区域中。在用户点击“上传视频”



§ 4.4 本章小结

线性组合的方式，生成目标的实例掩码。最后简要介绍了系统的界面设计包括了系统的流程图，系统界面设计的过程以及系统界面的展示。

第 5 章 实验环境与结果分析

§ 5.1 实验环境

在本文的实验中,采用 PyTorch 深度学习框架,操作系统环境为 Ubuntu 22.04,使用英伟达 GeForce RTX 3080 Ti 显卡对模型进行加速训练,显卡的显存为 12GB。实验的具体参数设置,如表 5-1 所示:

表 5-1 实验训练参数

序号	参数名称	参数值
1	Epochs(轮数)	150
2	ImgSz(图像尺寸)	640
3	Batch(批次)	16
4	Lr(学习率)	0.0001
5	Cache	True
6	Resume	True

在本文的实验参数中 Batch 是每次训练的过程中从训练集输入到模型的样本数;Lr(学习率)是用于控制模型参数更新的步长;Cache 是指开启缓存让模型的训练提高效率;Resume 是让模型从上次意外中断的地方恢复继续训练。

§ 5.2 实验结果分析

实验中使用了数据增强后的数据集进行训练,训练过程中的损失函数对模型预测出来的输出和真实的标签两者之间的偏差程度进行了量化。损失函数值越小,表明了模型的输出越接近真实值,性能也就越优越。损失值越大,表明了模型预测的输出与真实结果之间的差异越大,性能也就越差,需要对模型进行优化。实验训练过程中的四类损失函数,如图 5-1 所示。




图 5-1 训练过程中的损失函数曲线

图 5-1 中的四类损失函数图像，纵坐标分别代表了损失函数值，横坐标代表了训练的轮次。(a)表示训练过程中边界框损失函数的图像，边界框损失值可以用于评估模型在训练过程中预测的边界框与真实边界框之间的差异。边界框损失值从 1.34 逐步下降到 0.71，表明模型在学习更精准的定位目标。(b)表示训练过程中的分割损失函数的图像，分割损失函数值可以用于评估模型在训练过程中预测的分割掩码与真实掩码之间的差异，分割损失值从 3.89 逐步下降到 1.28，表明模型在学习更准确的分割不同目标。(c)表示训练过程中分类损失函数图像，分类损失值可以用来评估模型在训练过程中预测的目标类别与真实类别之间的差异，分类损失值从 2.32 下降到 0.55，表明模型在学习更精准的判断目标类别。(d)表示分布式焦点损失函数图像，分布式焦点损失用于改进边界框回归的分布差异，分布式焦点损失值从 1.32 下降到 0.98，表明模型在学习更精准的预测边界框。

模型在验证过程中主要是为了评估模型在验证集上的性能，以判断模型能否适应新的数据，验证过程中的损失函数值越小，表明了模型在新的数据中也能保持良好的准确性，具有很好的泛化能力，同时也表明模型没有出现过拟合的问题，而是学习到了数据中的特征信息。损失值越大，表明了模型的泛化能力比较差，无法

适应新的数据，同时也可能出现过拟合的问题。实验验证过程中的四类损失函数，如图 5-2 所示。




图 5-2 验证过程中的损失函数曲线

图 5-2 中的四类损失函数图像，纵坐标分别代表了损失函数值，横坐标代表了训练的轮次。(a)表示验证过程中边界框损失函数的图像，边界框损失值从 1.78 逐步下降到 0.88，表明模型在验证集上对目标的定位越来越准确。(b)表示验证过程中的分割损失函数的图像，分割损失值从 1.65 逐步下降到 1.16，表明模型在验证集上对不同的目标实例进行分割越来越准确。(c)表示训练过程中分类损失函数图像，分类损失值从 2.93 下降到 0.85，表明模型在验证集上对不同目标分类越来越准确。(d)表示分布式焦点损失函数图像，分布式焦点损失值从 1.62 下降到 0.98，表明模型在验证集上对目标边界框的预测越来越准确。

图 5-1 和图 5-2 的函数图像中，四类损失函数曲线总体呈下降的趋势，没有出现明显的波动，最终趋于稳定，表明模型在训练过程中收敛，未出现过拟合的问题，训练效果良好。

在本实验过程中使用 mAP 值来综合评估模型的性能，mAP 值的是所有类别的平均精度均值。它是一个综合的评价指标，综合考虑了模型的精确率和召回率，

mAP 曲线如图 5-3 所示。




图 5-3 mAP 曲线

图 5-3 的两类 mAP 曲线,纵坐标分别代表了目标检测 mAP 值和实例分割 mAP 值,横坐标同样代表了模型训练的次数。(a)代表了目标检测 mAP 值的图像, mAP 值从 0.37 逐步增加到了 0.80, 表明了模型在目标检测过程中的精度在不断提高,并且在达到一定的训练次数时,性能逐渐稳定。(b)代表了实例分割 mAP 值的图像, mAP 值从 0.25 逐步增加到了 0.70, 表明了模型在分割掩码方面的性能在随着训练轮数的增加也在不断提高。

在图 5-3 的图像中,两类曲线逐渐升高,最终趋于稳定状态,表明模型的检测任务和分割任务中的性能逐渐提高,具有较高的精度。

为了进一步验证经过训练之后模型的实际应用效果,特意选取了部分真实场景进行测试,如图 5-4 所示。



图 5-4 真实场景与检测结果

图 5-4 (a)中的真实场景检测目标包括:车辆、建筑物、树木和道路。检测数据

如表 5-2 所示。

表 5-2 真实场景检测数据

目标类别	目标数量	检测数量	准确率
车辆 (Car)	22	16	72%
建筑物 (Building)	9	8	88.8%
树木 (Tree)	6	5	83.3%
道路 (Road)	1	1	100%

从准确率中可以得出模型整体的真实性能和检测性能较为良好，但同时也存在对一些模糊小目标的识别能力较差以及掩码边界不够完整的问题，为之后模型的优化提供了方向。

§ 5.3 本章小结

本章主要介绍了本文的实验参数的设置和实验结果的分析与展示。首先在实验参数中，设置了合适的训练次数避免了模型过拟合和欠拟合的问题；设置了合适的批次充分利用了算力资源；设置了合适的学习率，有助于模型在训练后期稳定的收敛，避免了训练过程中的不稳定；设置了使用 `cache`，有助于加快模型的训练过程，提高速率；设置了使用 `resume`，避免因意外的中断，导致模型从头开始训练带来的时间浪费。然后对实验结果进行分析，具体介绍了训练和验证过程中的四类损失函数以及 `mAP` 函数曲线，最后对模型在真实场景应用的检测结果进行了分析。

第 6 章 总结与展望

§ 6.1 总结

本文针对多目标检测与分割的问题，设计并实现了一个多目标检测与分割系统，利用 YOLOv8 作为实例分割技术实现了对多目标的识别与像素级分割，同时也保证了快速检测的能力，有效的解决了传统方法效率低，语义信息丢失以及实时性不足的问题。系统通过 PySide6 技术搭建了交互式的界面，为用户提供了直观便捷的操作，系统中支持图片、视频和实时摄像数据的检测，可以满足用户不同的使用需求。在经过大量的实验和真实场景测试后，系统在多目标的场景中表现出了良好的稳定性和可靠性，能够有效的处理各类数据并完成检测与分割的任务。同时系统也使用了模块化的架构设计方法，各个功能模块在保证自身独立性的情况下，还可以实现相互配合、协同运作，为后续系统性能的优化以及功能的升级提供了便利。

§ 6.2 展望

本文的研究成果在一定程度上提升了现实场景中对多目标检测与分割任务中的性能，但仍有提升的空间。未来研究可以从多方面展开：

1. 在算法的性能方面，可以使用新的技术优化模型的网络结构，增强模型对复杂场景中不同大小目标的检测能力。
2. 在数据集方面，可以增加数据集的规模，减少对数据增强技术的依赖，使模型学习到更真实的特征分布。此外还可以考虑提高数据集标注的质量，减少标注过程中的人为失误。
3. 在实时性优化方面，可以借助硬件加速或者对算法进行轻量化的改进，提高模型的推理速度，推动该技术有更加广泛的应用。

参考文献

- [1] 音松,陈雪云,贝学宇.改进 Mask RCNN 算法及其在行人实例分割中的应用[J].计算机工程,2021,47(06):271-276+283.
- [2] 浦东,陈瑞,焦良葆,等.基于轻量级 Mask RCNN 的均压环歪斜检测[J].电力信息与通信技术,2021,19(05):95-102.
- [3] 许谨辉,王文善,王爽,等.基于 DYCS-YOLOv8n 的井下无人驾驶电机车多目标检测[J/OL].工矿自动化,1-8.
- [4] 陈晓东.基于 YOLO 车道多目标检测识别系统的研究[J].内燃机与配件,2025,(05):11-13.
- [5] HanifW M ,YuZ ,BashirR , et al.A new network model for multiple object detection for autonomous vehicle detection in mining environment[J].IET Image Processing,2024,18(12):3277-3287.
- [6] Yiming L ,Kaiwen W ,Wenshuo K , et al.Multi-object detection for crowded road scene based on ML-AFP of YOLOv5[J].Scientific Reports,2023,13(1):17310-17310.
- [7] 张纵驰,王华伟,周长威.MSA-YOLO:面向蒙皮表面缺陷的实时分割算法[J].航空计算技术,2024,54(05):64-68+73.
- [8] 李利,梁晶,陈旭东,等.基于 TLF-YOLOv8 的堆叠垃圾实例分割算法[J].科学技术与工程,2025,25(05):2009-2018.
- [9] 赵南南,高翥晨.基于改进 YOLOv8 的交通场景实例分割算法[J].计算机工程,2025,51(01):198-207.
- [10]Riza A F D ,Tulsi A A ,Momin A .Assessing cacao beans fermentation degree with improved YOLOv8 instance segmentation[J].Computers and Electronics in Agriculture,2024,227(P1):109507-109507.
- [11]Khan Z ,Liu H ,Shen Y , et al.Deep learning improved YOLOv8 algorithm: Real-time precise instance segmentation of crown region orchard canopies in natural environment[J].Computers and Electronics in Agriculture,2024,224109168-109168.
- [12]Bolya D ,Zhou C ,Xiao F , et al.YOLACT: Real-time Instance Segmentation. [J].CoRR,2019,abs/1904.02689
- [13]苏丽,孙雨鑫,苑守正.基于深度学习的实例分割研究综述[J].智能系统学

- 报,2022,17(01):16-31.
- [14] 曹行健,张志涛,孙彦赞,等.面向智慧交通的图像处理与边缘计算[J].中国图象图形学报,2022,27(06):1743-1767.
- [15] 郭琪周,袁春.基于空间语义信息特征融合的目标检测与分割[J].软件学报,2023,34(06):2776-2788.
- [16] 王聪,张珑.车辆实例分割算法研究[J].科技创新与应用,2020,(12):130-131.
- [17] 杨淑琴,马玉浩,方铭宇,等.基于实例分割的复杂环境车道线检测方法[J].浙江大学学报(工学版),2022,56(04):809-815+832.
- [18] 程远航,吴锐.基于图像实例分割的行人车辆检测识别方法[J].信息与电脑(理论版),2020,32(06):130-132.
- [19] 黄涛,李华,周桂,等.实例分割方法研究综述[J].计算机科学与探索,2023,17(04):810-825
- [20] 李晓筱,胡晓光,王梓强,等.基于深度学习的实例分割研究进展[J].计算机工程与应用,2021,57(09):60-67.
- [21] 陈茗杨,赵志刚,潘振宽,等.基于深度学习的图像实例分割[J].青岛大学学报(自然科学版),2019,32(01):46-50+54.
- [22] 陈励凡.基于深度学习的零件实例分割识别研究[J].电子技术与软件工程,2022,(21):189-193.

致 谢

已经到了毕业论文的最后一步，在河南科技大学西苑校区四年的学习生活也即将结束。回首四年光阴，目光所及，皆是回忆。我很高兴能够在这座充满活力的校园生活过，留下属于自己的一份美好回忆。

感谢我的父母，感谢他们二十三年的悉心照顾，在学业上的理解与支持，是我一直以来最坚强的后盾，他们总是能够在我最需要的时候出现，并给予我莫大的支持与鼓励。感谢他们的托举，我只不过是站在他们的肩膀上，去见识未曾见过的世界与繁华。春风化雨，皆是感恩，惟愿父母身体健康，平安喜乐。

感谢我的论文指导老师李昌清老师，李老师不仅是我的论文指导老师，还是我本科四年时光的学业导师。学生朽木，能够得到李老师的谆谆教诲是我莫大的荣幸。从论文选题到开题报告再到论文的正式写作过程中李老师都给予我耐心的指导。李老师的耐心与负责，让我在本科最后的求学生涯中受益匪浅。此外，我还要感谢软件学院的王珂老师，王老师对本篇论文的初稿多次提出了许多专业性的意见，同时也教会了我许多书本之外的知识，为本篇论文的修改提供了很大的便利。

感谢我的舍友们，能够在大学期间遇见一群很好的哥们，我的内心非常高兴，希望他们在毕业之后都能有一个美好而光明的未来，也能够找到属于自己的那一份天地。还要感谢我在大学生活中遇见的每一位同学，能遇见你们使我感到十分荣幸，在之后的日子里祝你们所遇皆良人，所行皆坦途。

感谢走的很慢但一直往前走的自己，这一路走来实属不易。我本是一个愚笨之人，从来不曾优秀过，也从来不曾放弃过。深夜的思索，朝阳的催促，教室里总有我的一个位置。我是一个典型的小镇做题家，从幼儿园到小学再到初中都是就读于村子里面的学校，到现在，这些学校已经消失很多年了。直到高中时，才去了县里的一所三流高中，成绩一直保持在中下等水平，第一年高考发挥一般，成绩中规中矩，之后毅然决然加入了复读大军，所幸第二年考上了科大。回首过往这一路，因为年少不懂事，确实走了一些弯路，好在及时醒悟，这才没有误入歧途。还要感谢自己的执着坚持，始终记得深夜在操场独自跑完 21 公里后，小腿抽筋不能走路，大腿僵硬不能动的场景。我愿珍藏这份光阴，因为这是我最美好的回忆。

最后感谢所有的相遇，感谢所有的经历。